



**DEPARTAMENTO
DE COMPUTACION**

Facultad de Ciencias Exactas y Naturales - UBA

Trabajo Práctico 1

Detección de Spam

27 de septiembre de 2016

Aprendizaje Automático

Integrante	LU	Correo electrónico
Fernández, Gonzalo	836/10	gpfernandezflorio@gmail.com
Damian, Aleman	377/10	damianealeman@gmail.com
Matías, Pizzagalli	257/10	matipizza@gmail.com



**Facultad de Ciencias Exactas y
Naturales**

Universidad de Buenos Aires

Ciudad Universitaria - (Pabellón I/Planta
Baja)

Intendente Güiraldes 2160 - C1428EGA

Ciudad Autónoma de Buenos Aires - Rep.
Argentina

Tel/Fax: (54 11) 4576-3359

<http://www.fcen.uba.ar>

Índice

Introducción

1. Metodología

Cargamos los mails de los archivos json. Extrajimos los atributos de la base de mails y los guardamos como matrices. Separamos los datos de entrenamiento de los de test utilizando la función `train_test_split` y almacenamos cada conjunto en archivos npy.

2. Extracción de atributos

Para saber que palabras identifican mejor a los mails de spam, implementamos un script que cuenta la cantidad de ocurrencias por palabra, relativa entre los mails de spam contra los de ham. Es decir, para cada palabra en los archivos json este script devuelve la cantidad de apariciones de dicha palabra en el archivo de spam menos la cantidad de apariciones de la misma palabra en el archivo ham. Este script está implementado en el archivo `wordCounter.py`. En el archivo `words-100.txt` se pueden ver las 100 palabras con mayor cantidad de ocurrencias relativa.

En principio usamos como atributos la cantidad de apariciones de estas palabras en cada mail. Por otro lado agregamos los atributos

- Cantidad de palabras en mayúsculas.
- Cantidad de palabras compuestas por números.
- Cantidad de palabras escritas con la primera letra en mayúscula.
- Cantidad de letras promedio por palabra.
- Cantidad de letras máxima por palabra.

Se pudo observar que a medida que íbamos agregando atributos, el modelo predictivo obtenía un valor más alto de accuracy y rápidamente se pudo llegar al 97% de accuracy.

3. Modelos

Utilizamos los siguientes algoritmos de aprendizaje:

- Decision Tree
- Random Forest
- Naive Bayes
- Vecinos Más Cercanos (KNN)
- Support Vector Machines (SVM)

4. Reducción de dimensionalidad

Sobre técnicas de reducción de dimensionalidad usamos:

PCA


ICA

iPCA

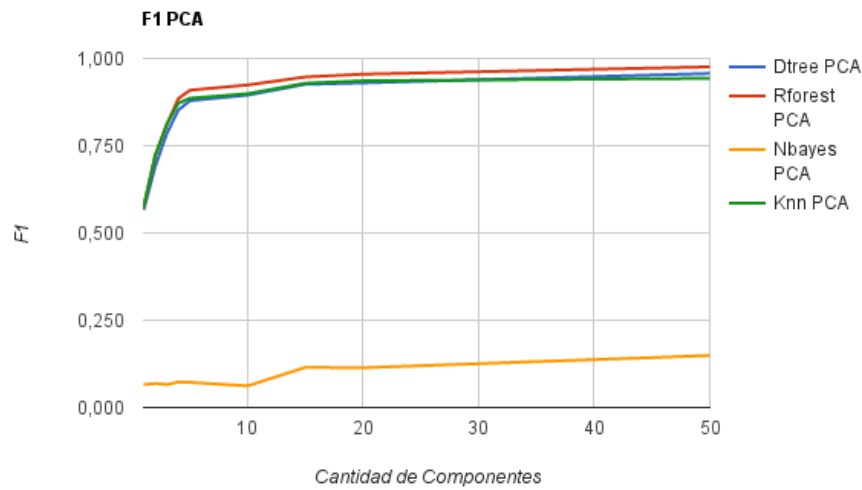
REFCV Con esta técnica vimos los atributos que ofrecen mayor poder predictivo

5. Resultados


Vimos como varía la medida de F1 a medida que incrementamos la cantidad




de componentes.




Comparamos los modelos según varias medidas de performance sobre los datos de test separados previamente (teniendo al mismo set de datos de test siempre

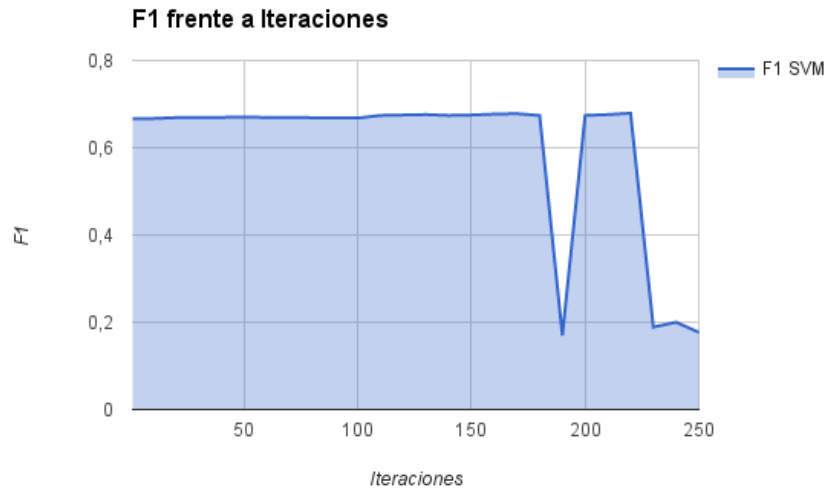


para realizar las mediciones de forma adecuada):



A continuación mostramos un gráfico que muestra la medida de F1 en función de la cantidad de iteraciones del modelo de Support Vector Machine:






6. Discusión

A continuación podemos ver los atributos con mayor poder predictivo seleccionados con el metodo de RFCV haciendo cross validation con $k = 5$ y $\text{step} = 1$. RFECV lo que hace es ir reduciendo la cantidad de atributos teniendo en cuenta un peso asociado que se obtiene a partir del estimador usado:

```
count_ESMTP
count_upper
count_guionba
count_dol
count_arr
count_and
count_equal
count_dotc
count_com
count_menor
count_menos
count_html
count_0600
count_2002
count_your
```

count_0800
count_align
count_0500
count_smtp
count_cec

En el siguiente gráfico mostramos que con 20 atributos se puede llegar al sco-



re optimo de cross validation.

Notamos en el gráfico que comapara F1 en función de la cantidad de componentes que con pocas componentes (5 o 6) ya se puede obtener un calor igual 0,90 y después las demás componentes (de la nueva base transformada) no mejoran demasiado la mérida de performance en cuestión.

Se puede observar que el mejor modelo es el de Random Forest, teniendo todas las méridas de performance en %99. Igualmente el modelo basado en arboles de decisión es muy cercano en cuanto a performance, no así los modelos implementados de Naive Bayes y de Support Vector Machines. Por último el modelo de Vecinos más cercanos tiene un %94 de accuracy. Dado que sabemos que Random Forest tuvo mejores méridas (incluso teniendo en cuenta el desvíó estandard) lo elegimos como el modelos para ser usado en la competencia.

Por ultimo es importante destacar que el modelo SVM mejora hasta una cierta cantidad de iteraciones(aproximadamente 10000) y luego la performance empieza a disminuir.